TD– Barcoding pollinisateurs – M. OLLIVIER

Analyse d'un jeu de données sur les Bourdons

1. Exploration de la plateforme et des données publiques

Rendez-vous sur la plateforme BOLD system : https://boldsystems.org/

a. Combien de séquences de référence (*barcodes*) sont disponibles publiquement sur la plateforme ?
b. Combien d'espèce cela représente-t-il ? A quels règnes appartiennent ces espèces ?
c. Qu'est-ce qu'un BIN ? Quelles opportunité cette approche offre-t-elle ?
d. Réaliser l'identification d'une séquence inconnue.

Cliquer sur Barcode ID dans le menu déroulant « Data ». Rappelez les étapes de l'identification par barcoding. choisissez la base de données que vous souhaitez utiliser sachant que les informations que vous possédez sur le spécimen séquencé sont les suivantes : « *Apoïde Anthophile, capturé au filet en juillet en Allemagne, et se nourrissant sur Scabieuse*. » Copiez la séquence et collez-la dans l'encart dédié.

Séquence :
TATACTATATTTTATATTTGCTATATGATCGGGAATAGTTGGAGCTTCTTTAAGTATAATTATTCGTTTAGAATTA
AGTGCTCCAGGAAGATGAATTAATAATGATCAAATTTATAATACTATTGTAACTTCTCATGCTTTTGTTATAATT
TTTTTTATAGTTATACCATTTATAATTGGAGGATTCGGAAATTGACTAGTACCATTAATAATTGGAGCCCCTGAT
ATAGCATTTCCACGAATAAATAATATAAGATTTTGACTATTAATACCATCTTTATTTATACTTATTATAAGAGTAA
CTTTATCAACAGGTTCAGGAACAGGTTGAACTATATATCCTCCTTTATCATCAATTATATATCACTCATCCTATGC
TATAGATTTTACTATTTTTTCTCTACATATTGCAGGAATTTCTTCAATTATAGGAGCTATTAATTTTATTGTTTCAA
TTTTATTAATGAAAAATATTTCACTTAATTTAAATCAAATTCCTTTATTCCCATGATCAGTTAAAATTACTGCAAT
TTTATTACTATTATCTTTACCTGTCTTAGCAGGAGCTATCACTATATTATTAACTGACCGAAATTTAAATACTTCC
TTTTTTGACCCCTCAGGAGGAGGAGATCCTATTTTATATCAACATTTATTT

Quelle base de référence avez-vous choisi ? Qu'indique le résultat de l'indentification ? Sur quoi vous appuyez-vous pour affirmer qu'il s'agit bien de cette espèce ?

2. Analyses des données du projet

Cliquer sur *Workbench* dans le bandeau en haut, puis *Login* dans le menu déroulant.

Entrer le Username : **promoabsv31**, et le Mdp : **promoABSV31***

Avant-propos : Vous allez travailler à partir d'un jeu de données contenant des séquences de bourdons (*Bombus sp*.). Celles-ci ont été produites dans le cadre d'un projet (CODABEILLES) dont l'objectif est de constituer une base publique et fiable des *barcodes* de références pour permettre l'identification moléculaires des abeilles sauvages de France.

a. Cliquer sur le jeu de données « DS-BBBABSV Dataset of Bumblebee species for a course with ABSV students »

Quelles informations apparaissent à l'écran ? Pouvez-vous décrire le jeu de données ? (Nombre de spécimens, de séquences et d'espèces, provenance, âge des spécimens séquencés, marqueur génétique, longueur du fragment, qualité…).

b. Cliquer sur « View all reccords » dans la marge de gauche.

Quels champs contient de tableau qui vous est présenté ? Expliquez ce que signifie chaque colonne. Pourquoi certaines entrées ne sont associées à aucune séquence ? quelles pourraient en être les raisons ?

c. Sélectionner toutes les séquences et construisez un arbre de distance.

Dans le menu de gauche, sélectionner *Sequence Analysis/Taxon ID Tree*.

Expliquez ce que signifies les paramètres que vous allez sélectionner.

Entrez les paramètres suivants :

Tree Type = Multipage Classic,
Sequence Data = Nucleotide,
Distance Model = Kimura 2 P,
Align Sequences = MUSCLE,
Select Branch Labels = Sample ID + Taxon + Sex + State/Province + Region + BIN URI
Apply filters = […] >200 bp
Colorize Tree Based on = Barcode Cluster (BIN)
Ambigous Base = Pairwise Deletion
Minimum Complete Overlap = 100 bp
Codon Positions Included = 1, 2, 3
Result Options = View immediately

En observant la topologie de cet arbre, pouvez-vous identifier des spécimens susceptibles d'être mal identifiés ? Sur quoi vous appuyez-vous pour dire cela ? Que faudra-t-il faire pour le confirmer ? Noter la liste des séquences mal identifiées.

En observant la topologie de l'arbre, êtes-vous capables de préciser à quelle espèce appartient le spécimen identifié morphologiquement seulement au genre (*Bombus* sp.) ?

d. Retournez sur la « Records List », décochez les séquences associées à des erreurs d'identification potentielles. Effectuer l'analyse de « Barcode Gap Analysis » avec les séquences restantes.

Entrez les paramètres suivants :

Distance Model = Kimura 2 P,
Marker = COI-5P,
Alignment Options = MUSCLE,
Apply Filters = […] > 200 bp,
Ambigous Base = Pairwise Deletion
Result Options = View immediately

- **Scatter Plots** : Prenez 5 min pour lire attentivement la légende, par binôme tentez de comprendre la construction du graphique. Que représente la droite rouge ? Comment l'interpréter ?
- **Distance Distribution Histograms** : Expliquez les histogrammes représentés.
- Pour être en capacité de discriminer deux espèces à partir de leurs séquences respectives, comment doit être la distance génétique entre ces deux espèces (distance interspécifique) par rapport à la distance intraspécifique pour chacune de ces espèces ?
- Que montrent les données que vous analysez ? Cette condition est-elle respectée pour tous les spécimens du genre *Bombus sp.* séquencés ici ?
- **Details for Specimens Comparisons** : Aidez-vous des données contenues dans ce tableau pour identifier précisément les spécimens pouvant poser problème. Pour clarifier cette situation quelles seraient les perspectives de travail à mettre en œuvre ?

3. Analyses intégrant les données mondiales

Si vous êtes arrivés jusqu'ici, bravo ! Et si vous êtes les premiers alors suivez les étapes de la partie a. sinon allez directement à la partie b.

Dans cette dernière partie, vous allez confronter les données du projet CODABEILLES aux autres séquences disponibles publiquement, et déposées par d'autres laboratoires de recherches. Ceci afin de discuter avec plus de recul vos séquences.

a. Création d'un dataset complet intégrant les données publiques (ATTENTION : cette étape est réalisée par un seul binôme pour toutes les personnes connectées sur le compte « promoabsv31 »)

Cliquer sur « Record Search » en haut de la page, noter « Bombus » dans la Taxonomie, indiquer le marqueur recherché, et les tailles minimum et maximum de 400 et 700 nucléotides. En cliquant sur l'onglet « Region of Map », tracer un polygone couvrant l'Europe occidentale. Décocher « Search within project [DS-BBBABSV] » et cocher « Include public records ».

Sélectionner l'ensemble des records trouvés (Select -> All), puis faire « Options » (menu de gauche) et « Add records to dataset ». Selectionner « DS-BOMB26 ». Ajouter les données du dataset « DS-BBBABSV » à ce jeu de données également, en suivant la même procédure.

b. Inférer un nouvel arbre de distance plus complet

A partir du jeu de donnée « DS-BOMB26 » qui apparait maintenant dans votre tableau de bord, construire un autre arbre de distance pour discuter les séquences de CODABEILLES. Remarquez-vous des anomalies que vous n'aviez pas identifié jusqu'à présent ? Les conclusions que vous avez tirées précédemment sur les séquences posant des problèmes sont-elles toujours valables ?

c. Exploration libre de la boite à outils BOLD

Sur le temps restant, vous pouvez explorer d'autres outils d'analyses de la palette de gauche comme « Distance Summary », « Geo-distance Correlation », « Accumulation curve », « BIN Discordance ». Discutez entre vous les résultats et avec l'animateur du TD.